

# Álgebra



**Universidad  
Internacional  
de Valencia**  
**Máster Universitario  
en Inteligencia Artificial**

**02MIAR | Matemáticas:**  
Matemáticas para la Inteligencia Artificial

**Profesor:**  
Víctor M. Campello

## Definición

*Un vector real  $v$  de dimensión  $n$  es una lista ordenada de  $n$  números reales:*


$$v = (v_1, v_2, \dots, v_n), \quad v_i \in \mathbb{R}.$$

*Se denota por  $\mathbb{R}^n$  el conjunto formado por todos los vectores de dimensión  $n$ . Por tanto, podemos escribir  $v \in \mathbb{R}^n$ .*

## Ejemplos

1.  $v = (1, -\frac{2}{3}) \in \mathbb{R}^2$ .
2.  $w = (\sqrt{2}, -1.2, \pi) \in \mathbb{R}^3$ .

Los vectores en  $\mathbb{R}^n$  se pueden interpretar de forma gráfica mediante un sistema de  $n$  coordenadas. En caso de tener una dimensión de  $n = 3$  o inferior, éstos se pueden dibujar.



## Definición

*Dados dos vectores  $v, w \in \mathbb{R}^n$ ,  $v = (v_1, v_2, \dots, v_n)$ ,  $w = (w_1, w_2, \dots, w_n)$ , podemos definir su suma como*

$$v + w = (v_1 + w_1, v_2 + w_2, \dots, v_n + w_n).$$

## Definición

*Dado un valor real  $\lambda \in \mathbb{R}$  (escalar) y un vector  $v \in \mathbb{R}^n$ ,  $v = (v_1, v_2, \dots, v_n)$ , podemos definir su producto como*

$$\lambda \cdot v = (\lambda v_1, \lambda v_2, \dots, \lambda v_n).$$

La longitud de los vectores se puede medir a través de **normas**. Algunas normas vectoriales importantes son:

- ▶ Norma euclídea:

$$\|v\|_2 = \sqrt{\sum_{i=1}^n v_i^2} = \sqrt{v_1^2 + v_2^2 + \cdots + v_n^2}.$$

- ▶ Norma 1:

$$\|v\|_1 = \sum_{i=1}^n |v_i| = |v_1| + |v_2| + \cdots + |v_n|.$$

- ▶ Norma del máximo:

$$\|v\|_\infty = \max_{1 \leq i \leq n} |v_i|.$$

## Ejemplo

*Construimos un modelo de machine learning para predecir las temperaturas a partir de algunas variables de entrada (input). Supongamos que obtenemos un conjunto de  $n$  predicciones con el modelo considerado, almacenadas en un vector:*

$$\hat{v} = (\hat{v}_1, \hat{v}_2, \dots, \hat{v}_n) \in \mathbb{R}^n.$$

*Comparamos ahora el vector de predicciones,  $\hat{v}$ , con el vector de respuestas reales (observaciones),  $v = (v_1, \dots, v_n)$ . Una forma de hacerlo es utilizar alguna norma sobre la diferencia de los dos vectores:*

$$E = \frac{1}{n} \|\hat{v} - v\|.$$

*Objetivo: encontrar un algoritmo que minimice  $E$ .*

El producto escalar entre dos vectores  $v, w \in \mathbb{R}^n$  se define como:

$$v \cdot w = \sum_{i=1}^n v_i w_i.$$

## Ejemplo

Sean  $v, w \in \mathbb{R}^3$ , con  $v = (2, -1, 0)$  y  $w = (-3, -2, 1)$ . Entonces

$$\begin{aligned} v \cdot w &= (2, -1, 0) \cdot (-3, -2, 1) \\ &= 2 \cdot (-3) + (-1) \cdot (-2) + 0 \cdot 1 = -6 + 2 + 0 = -4. \end{aligned}$$

## Definición


Sean  $u, v \in \mathbb{R}^n$ . Definimos la **proyección** de  $u$  sobre  $v$  como

$$\text{Proj}_v(u) = \frac{u \cdot v}{v \cdot v} v.$$

## Definición

Sean  $u, v \in \mathbb{R}^n$ . Definimos la **ortogonal** de  $u$  sobre  $v$  como

$$\text{Ort}_v(u) = u - \text{Proj}_v(u).$$





## Definición

*Diremos que dos vectores  $u, v \in \mathbb{R}^n$  son **ortogonales** si  $u \cdot v = 0$ .*

La definición de ortogonalidad entre dos vectores se corresponde con la noción geométrica de perpendicularidad.

Más concretamente,

$$u \cdot v = \|u\|_2 \|v\|_2 \cos(\widehat{uv}),$$

donde  $\widehat{uv}$  es el ángulo que forman los vectores  $u$  y  $v$ .

## Propiedades

Para  $u, v, w \in \mathbb{R}^n$  y  $a \in \mathbb{R}$ :

- ▶  $u + v = v + u.$
- ▶  $u \cdot v = v \cdot u.$
- ▶  $u \cdot (v + w) = u \cdot v + u \cdot w.$
- ▶  $(a \cdot u) \cdot v = a \cdot (u \cdot v).$
- ▶  $v \cdot v = \|v\|_2^2.$
- ▶  $u \cdot v = 0$  si y sólo si  $u$  y  $v$  son ortogonales.
- ▶  $v \cdot u = v \cdot \text{Proj}_v(u).$
- ▶  $\text{Ort}_v(u) \cdot v = 0$

## Definición

Dados  $v_1, v_2, \dots, v_k \in V$ , una **combinación lineal** de los  $k$  vectores anteriores es cualquier expresión de la forma

$$a_1 v_1 + a_2 v_2 + \dots + a_k v_k,$$

con  $a_1, a_2, \dots, a_k \in K$ .

## Definición

Sean  $v_1, v_2, \dots, v_k \in V$ . Diremos que los vectores anteriores son **linealmente independientes** si se cumple que la ecuación

$$a_1 v_1 + a_2 v_2 + \dots + a_k v_k = 0$$

tiene como única solución  $a_1 = a_2 = \dots = a_k = 0$ . En caso contrario, se dice que dichos vectores son **linealmente dependientes**.

## Definición

Una **matriz** de tamaño  $m \times n$  sobre el cuerpo de los números reales  $\mathbb{R}$  es un conjunto formado por  $m \cdot n$  valores reales,  $a_{i,j}$ ,  $1 \leq i \leq m$ ,  $1 \leq j \leq n$ , distribuidos en  $m$  filas y  $n$  columnas de la siguiente forma:

$$A = \begin{pmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m,1} & a_{m,2} & \cdots & a_{m,n} \end{pmatrix}.$$

Escribimos  $A \in \mathbb{R}^{m \times n}$ , siendo  $\mathbb{R}^{m \times n}$  el conjunto formado por todas las matrices  $m \times n$ . Asimismo, diremos que una matriz  $A \in \mathbb{R}^{m \times n}$  es **cuadrada** si  $m = n$ , es decir, si tiene el mismo número de filas y de columnas.

Sean  $A, B \in \mathbb{R}^{m \times n}$ . Podemos definir la **suma** y la **resta**  $A \pm B$  como:

$$A \pm B = \begin{pmatrix} a_{1,1} \pm b_{1,1} & a_{1,2} \pm b_{1,2} & \cdots & a_{1,n} \pm b_{1,n} \\ a_{2,1} \pm b_{2,1} & a_{2,2} \pm b_{2,2} & \cdots & a_{2,n} \pm b_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m,1} \pm b_{m,1} & a_{m,2} \pm b_{m,2} & \cdots & a_{m,n} \pm b_{m,n} \end{pmatrix}$$

Asimismo, dado un escalar  $\lambda \in \mathbb{R}$ , definimos el **producto**  $\lambda \cdot A$  como

$$\lambda A = \begin{pmatrix} \lambda a_{1,1} & \lambda a_{1,2} & \cdots & \lambda a_{1,n} \\ \lambda a_{2,1} & \lambda a_{2,2} & \cdots & \lambda a_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda a_{m,1} & \lambda a_{m,2} & \cdots & \lambda a_{m,n} \end{pmatrix}$$

Por último, si  $A \in \mathbb{R}^{m \times s}$  y  $B \in \mathbb{R}^{s \times n}$ , entonces definimos el **producto matricial**  $A \cdot B \in \mathbb{R}^{m \times n}$  como

$$A \cdot B = \begin{pmatrix} c_{1,1} & c_{1,2} & \cdots & c_{1,n} \\ c_{2,1} & c_{2,2} & \cdots & c_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m,1} & c_{m,2} & \cdots & c_{m,n} \end{pmatrix}$$

donde  $c_{i,j} = \sum_{k=1}^s a_{i,k} b_{k,j} = a_{i,1} b_{1,j} + a_{i,2} b_{2,j} + \cdots + a_{i,s} b_{s,j}$ .

## Nota

En general, el producto de matrices **NO** es conmutativo. Por ejemplo:

$$\begin{pmatrix} 1 & 0 \\ -1 & 2 \end{pmatrix} \cdot \begin{pmatrix} 0 & 1 \\ -3 & 4 \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ -6 & 7 \end{pmatrix}$$
$$\begin{pmatrix} 0 & 1 \\ -3 & 4 \end{pmatrix} \cdot \begin{pmatrix} 1 & 0 \\ -1 & 2 \end{pmatrix} = \begin{pmatrix} -1 & 2 \\ -7 & 8 \end{pmatrix}$$

## Definición

Sea  $A \in \mathbb{R}^{n \times n}$ . Diremos que  $A$  es **invertible** o **regular** si  $\exists B \in \mathbb{R}^{n \times n}$  tal que  $A \cdot B = B \cdot A = I_n$ . La matriz  $B$  recibe el nombre de **matriz inversa** y se denota por  $A^{-1}$ .

## Definición

Sea  $A \in \mathbb{R}^{n \times n}$  una matriz cuadrada de la forma

$$\begin{pmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & a_{n,2} & \cdots & a_{n,n} \end{pmatrix}.$$

Definimos el **determinante** de  $A$  de forma recurrente como sigue:

► Si  $n = 1$ ,  $\det(A) = a_{1,1}$ .

► Para  $n > 1$ ,

$$\det(A) = \sum_{j=1}^n (-1)^{1+j} a_{1,j} \det(A_{1,j}),$$

donde  $A_{i,j} \in \mathbb{R}^{(n-1) \times (n-1)}$  es la matriz resultante de eliminar en  $A$  la fila  $i$  y la columna  $j$ .



## Teorema

*El determinante de una matriz  $A$  puede calcularse de cualquiera de las siguientes formas:*

- ▶ *Desarrollo por la fila  $i$ ,  $1 \leq i \leq n$ :*

$$\det(A) = \sum_{j=1}^n (-1)^{i+j} a_{i,j} \det(A_{i,j}).$$

- ▶ *Desarrollo por la columna  $j$ ,  $1 \leq j \leq n$ :*

$$\det(A) = \sum_{i=1}^n (-1)^{i+j} a_{i,j} \det(A_{i,j}).$$

*donde  $A_{i,j} \in \mathbb{R}^{(n-1) \times (n-1)}$  es la matriz resultante de eliminar en  $A$  la fila  $i$  y la columna  $j$ .*

## Teorema

$\forall A, B \in \mathbb{R}^{n \times n}$ , se cumple

$$\det(A \cdot B) = \det(A) \cdot \det(B).$$

## Teorema

$A \in \mathbb{R}^{n \times n}$  es regular si y sólo si  $\det(A) \neq 0$ .

## Definición

El **rango** de una matriz  $A \in \mathbb{R}^{m \times n}$  es el número máximo de columnas que, como vectores, son linealmente independientes entre sí. Se denota por  $\text{rank}(A)$ .

## Teorema

$A \in \mathbb{R}^{n \times n}$  es regular si y sólo si  $\text{rank}(A) = n$ .

## Definición

Sea  $A \in \mathbb{R}^{m \times n}$ . La **traspuesta** de la matriz  $A$  se define como la matriz  $A' \in \mathbb{R}^{n \times m}$  tal que  $A'(i, j) = A(j, i)$ ,  $1 \leq i \leq n$ ,  $1 \leq j \leq m$ .

## Teorema

Sea  $A \in \mathbb{R}^{n \times n}$  regular. Entonces la inversa de  $A$ ,  $A^{-1}$ , viene dada por

$$A^{-1} = \frac{1}{\det(A)} \cdot \text{adj}(A),$$

donde  $\text{adj}(A)$  es la **matriz adjunta** de  $A$ , dada por  $\text{adj}(A) = C'$ , con  $C(i, j) = (-1)^{i+j} |A_{i,j}|$ ,  $1 \leq i, j \leq n$ , con  $|A_{i,j}| = \det(A_{i,j})$ .

## Definición

Diremos que una aplicación  $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$  es una **aplicación lineal** si  $\forall u_1, u_2 \in \mathbb{R}^n$  y  $\forall a, b \in \mathbb{R}$  se cumple

$$f(au_1 + bu_2) = af(u_1) + bf(u_2).$$

## Ejemplos

1. La aplicación  $f : \mathbb{R}^3 \rightarrow \mathbb{R}^2$  dada por  $f(x, y, z) = (x + y, 2z - x)$  es lineal.
2. La aplicación  $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$  dada por  $f(x, y) = (x, x^2 - y)$  no es lineal.
3. La aplicación  $f : \mathbb{R}^2 \rightarrow \mathbb{R}^2$  dada por  $f(x, y) = (x - y, x + 1)$  no es lineal.

## Teorema

*Toda aplicación lineal  $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$  tiene una matriz que la representa, que además es única. Concretamente,  $\exists! M_f \in \mathbb{R}^{m \times n}$  tal que  $\forall v \in \mathbb{R}^n$  puede escribirse:*

$$f(v) = M_f v.$$

## Ejemplo

Sea  $f : \mathbb{R}^3 \rightarrow \mathbb{R}^4$  dada por

$$f(x, y, z) = \begin{pmatrix} x + y \\ y - z \\ 2x + y + z \\ 3z \end{pmatrix} \rightarrow M_f = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & -1 \\ 2 & 1 & 1 \\ 0 & 0 & 3 \end{pmatrix}$$

## Teorema

Sea  $f : \mathbb{R}^n \rightarrow \mathbb{R}^s$  y  $g : \mathbb{R}^s \rightarrow \mathbb{R}^m$  aplicaciones lineales, con  $M_f$  y  $M_g$  las matrices que las representan, respectivamente. Entonces  $g \circ f : \mathbb{R}^n \rightarrow \mathbb{R}^m$  es una aplicación lineal, cuya matriz que la representa viene dada por  $M_{g \circ f} = M_g M_f$ .

## Ejercicios

1. Comprueba que el teorema se cumple para los dos ejemplos anteriores.
2. Probar el teorema para dos aplicaciones lineales cualesquiera. Es decir, probar lo siguiente:
  - 2.1  $g \circ f$  es una aplicación lineal si  $f$  y  $g$  lo son.
  - 2.2 La matriz que representa  $g \circ f$ ,  $M_{g \circ f}$ , puede escribirse como el producto de las matrices que representan  $g$  y  $f$ , esto es,  $M_g M_f$ .

## Ejemplo

*Un ejemplo clásico de aplicaciones lineales son las rotaciones. En el caso de  $\mathbb{R}^2$  vienen dadas por  $f_\theta : \mathbb{R}^2 \rightarrow \mathbb{R}^2$  definidas como:*

$$f_\theta(x, y) = \begin{pmatrix} \cos(\theta)x - \sin(\theta)y \\ \sin(\theta)x + \cos(\theta)y \end{pmatrix} \rightarrow M_{f_\theta} = \begin{pmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{pmatrix},$$

*donde  $\theta$  representa el ángulo de rotación (en sentido antihorario). Por tanto, esta aplicación envía un vector  $(x, y) \in \mathbb{R}^2$  a su correspondiente versión rotada  $\theta$  grados:  $(\cos(\theta)x - \sin(\theta)y, \sin(\theta)x + \cos(\theta)y)$ . Asimismo, y como ya sabemos, podemos expresar la transformación matricialmente:*

$$f_\theta(x, y) = \begin{pmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}.$$

## Ejemplo

*Por ejemplo, la rotación de  $30^\circ$  (o  $\pi/6$  rad) viene dada por:*

$$f_{\pi/6} \equiv \begin{pmatrix} \cos\left(\frac{\pi}{6}\right) & -\sin\left(\frac{\pi}{6}\right) \\ \sin\left(\frac{\pi}{6}\right) & \cos\left(\frac{\pi}{6}\right) \end{pmatrix} = \begin{pmatrix} \frac{\sqrt{3}}{2} & -\frac{1}{2} \\ \frac{1}{2} & \frac{\sqrt{3}}{2} \end{pmatrix}$$

*Por otra parte, la rotación de  $60^\circ$  (o  $\pi/3$  rad) viene dada por:*

$$f_{\pi/3} \equiv \begin{pmatrix} \cos\left(\frac{\pi}{3}\right) & -\sin\left(\frac{\pi}{3}\right) \\ \sin\left(\frac{\pi}{3}\right) & \cos\left(\frac{\pi}{3}\right) \end{pmatrix} = \begin{pmatrix} \frac{1}{2} & -\frac{\sqrt{3}}{2} \\ \frac{\sqrt{3}}{2} & \frac{1}{2} \end{pmatrix}$$

*Por tanto, si componemos sendas rotaciones queda:*

$$f_{\pi/3} \circ f_{\pi/6} \equiv \begin{pmatrix} \frac{\sqrt{3}}{2} & -\frac{1}{2} \\ \frac{1}{2} & \frac{\sqrt{3}}{2} \end{pmatrix} \begin{pmatrix} \frac{1}{2} & -\frac{\sqrt{3}}{2} \\ \frac{\sqrt{3}}{2} & \frac{1}{2} \end{pmatrix} = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$$



## Ejemplo

*Cabe esperar que el resultado sea una rotación de  $90^\circ$  (o  $\pi/2$  rad) con respecto al original:*

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} -y \\ x \end{pmatrix}$$

*cumpléndose  $(x, y) \cdot (-y, x) = -xy + yx = 0$ , luego son ortogonales.*


## Ejercicio

*Utilizando las identidades trigonométricas que procedan, demuestra los siguientes enunciados:*

(a)  $\|f_\theta(v)\|_2 = \|v\|_2 \quad \forall v \in \mathbb{R}^2, \forall \theta \in \mathbb{R}.$

(b)  $f_\beta \circ f_\alpha = f_{\alpha+\beta} \quad \forall \alpha, \beta \in \mathbb{R}.$

Las matrices (y las aplicaciones lineales que representan) constituyen un elemento importante en la descripción de redes neuronales.




$$a_1^R = f_1 (\omega_{1,1} a_1^L + \omega_{1,2} a_2^L + \omega_{1,3} a_3^L + b_1) ,$$
$$a_2^R = f_2 (\omega_{2,1} a_1^L + \omega_{2,2} a_2^L + \omega_{2,3} a_3^L + b_2) .$$

$$W = \begin{pmatrix} \omega_{1,1} & \omega_{1,2} & \omega_{1,3} \\ \omega_{2,1} & \omega_{2,2} & \omega_{2,3} \end{pmatrix} , \quad a^L = \begin{pmatrix} a_1^L \\ a_2^L \\ a_3^L \end{pmatrix} .$$

$$a_1^R = f_1 (W(1, :) a^L + b_1) ,$$
$$a_2^R = f_2 (W(2, :) a^L + b_2) .$$

En general, para el caso de información de una capa de  $n$  neuronas que se transmite a otra capa de  $m$  neuronas:



$$a_i^R = f_i \left( \sum_{j=1}^n \omega_{i,j} a_j^L + b_i \right), \quad 1 \leq i \leq m.$$

$$W = \begin{pmatrix} \omega_{1,1} & \omega_{1,2} & \cdots & \omega_{1,n-1} & \omega_{1,n} \\ \omega_{2,1} & \omega_{2,2} & \cdots & \omega_{2,n-1} & \omega_{2,n} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ \omega_{m-1,1} & \omega_{m-1,2} & \cdots & \omega_{m-1,n-1} & \omega_{m-1,n} \\ \omega_{m,1} & \omega_{m,2} & \cdots & \omega_{m,n-1} & \omega_{m,n} \end{pmatrix},$$

$$a^L = \begin{pmatrix} a_1^L \\ a_2^L \\ \vdots \\ a_{n-1}^L \\ a_n^L \end{pmatrix} \rightarrow a_i^R = f_i \left( W(i,:) a^L + b_i \right), \quad 1 \leq i \leq m.$$

## Definición

Sea  $A \in \mathbb{R}^{n \times n}$  una matriz cuadrada. Un **vector propio** o **autovector**  $v \in \mathbb{R}^{n \times 1}$ ,  $v \neq \vec{0}$ , asociado a  $A$  es aquel que cumple que  $\exists \lambda \in \mathbb{R}$  tal que  $Av = \lambda v$ . El valor  $\lambda$  recibe el nombre de **valor propio** o **autovalor** de  $A$  asociado al autovector  $v$ .

## Ejemplo

Sea  $A = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix}$ .  $\lambda_1 = 2$  y  $\lambda_2 = -3$  son valores propios de  $A$  asociados a los vectores propios  $v_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$  y  $v_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ , resp.:

$$Av_1 = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \end{pmatrix} = 2 \begin{pmatrix} 2 \\ 1 \end{pmatrix} = 2v_1,$$

$$Av_2 = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -3 \\ -3 \end{pmatrix} = -3 \begin{pmatrix} 1 \\ 1 \end{pmatrix} = -3v_2.$$

- ▶ ¿Qué interés tiene conocer los autovalores y autovectores?
- ▶ Supongamos que, dada  $A \in \mathbb{R}^{n \times n}$ , conseguimos encontrar  $n$  autovectores linealmente independientes,  $\{v_i\}_{i=1}^n$  (base de  $\mathbb{R}^n$ ), asociados respectivamente a  $n$  autovalores,  $\{\lambda_i\}_{i=1}^n$ .
- ▶ Por definición, se tiene  $Av_i = \lambda_i v_i$  para  $1 \leq i \leq n$ .
- ▶ Denotamos  $P \in \mathbb{R}^{n \times n}$  a la matriz formada por los vectores propios dispuestos en columna y  $D$  a la matriz diagonal formada por los valores propios:

$$P = \begin{pmatrix} \uparrow & \uparrow & & \uparrow \\ v_1 & v_2 & \cdots & v_n \\ \downarrow & \downarrow & & \downarrow \end{pmatrix}, \quad D = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{pmatrix}.$$

- ▶ Entonces se cumple  $AP = PD$ . Equivalentemente:  $P^{-1}AP = D$ .
- ▶  $(AP)(:,j) = AP(:,j) = Av_j = \lambda_j v_j = PD(:,j) = (PD)(:,j)$ .

## Ejemplo

Anteriormente vimos que los vectores propios de  $A = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix}$  son  $v_1 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$  y  $v_2 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$ , asociados, respectivamente, a los autovalores  $\lambda_1 = 2$  y  $\lambda_2 = -3$ . Definimos

$$P = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}, \quad D = \begin{pmatrix} 2 & 0 \\ 0 & -3 \end{pmatrix}$$

$$AP = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} = \begin{pmatrix} \uparrow & \uparrow \\ Av_1 & Av_2 \\ \downarrow & \downarrow \end{pmatrix} = \begin{pmatrix} 4 & -3 \\ 2 & -3 \end{pmatrix}$$

$$PD = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} 2 & 0 \\ 0 & -3 \end{pmatrix} = \begin{pmatrix} \uparrow & \uparrow \\ \lambda_1 v_1 & \lambda_2 v_2 \\ \downarrow & \downarrow \end{pmatrix} = \begin{pmatrix} 4 & -3 \\ 2 & -3 \end{pmatrix}$$

## Definición

Sea  $A \in \mathbb{R}^{n \times n}$  una matriz cuadrada. Diremos que  $A$  es **diagonalizable** si  $\exists P \in \mathbb{R}^{n \times n}$  regular y  $D \in \mathbb{R}^{n \times n}$  diagonal tales que

$$P^{-1}AP = D.$$

- ▶ ¿Qué utilidad tiene diagonalizar una matriz?
- ▶ Cálculo del determinante:

$$\begin{aligned}\det(A) &= \det(PDP^{-1}) = \det(P) \det(D) \det(P^{-1}) \\ &= \det(P) \det(D) \frac{1}{\det(P)} = \det(D) = \prod_{i=1}^n \lambda_i.\end{aligned}$$

- ▶ Cálculo del rango:

$$\text{rank}(A) = |\{\lambda_i \mid \lambda_i \neq 0, 1 \leq i \leq n\}|.$$

- ▶ Cálculo de potencias matriciales.

Si  $P^{-1}AP = D$ , entonces multiplicando por  $P$  a la izquierda y  $P^{-1}$  a la derecha podemos obtener

$$A = PDP^{-1}.$$

- ▶  $A^2 = A \cdot A = (PDP^{-1})(PDP^{-1}) = PD(P^{-1}P)DP^{-1} = PD I_n DP^{-1} = P(D \cdot D)P^{-1} = PD^2P^{-1}.$
- ▶  $A^3 = A^2 \cdot A = (PD^2P^{-1})(PDP^{-1}) = PD^2(P^{-1}P)DP^{-1} = PD^2 I_n DP^{-1} = P(D^2D)P^{-1} = PD^3P^{-1}.$
- ▶ En general, se tiene

$$A^k = PD^kP^{-1}, \text{ donde } D^k = \begin{pmatrix} \lambda_1^k & 0 & \cdots & 0 \\ 0 & \lambda_2^k & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n^k \end{pmatrix}.$$



- ▶ Si  $A \in \mathbb{R}^{n \times n}$ ,  $\lambda \in \mathbb{R}$  es un valor propio de  $A$  y  $v \in \mathbb{R}^{n \times 1}$  es un vector propio asociado a  $\lambda$ , entonces:

$$Av = \lambda v \Leftrightarrow Av - \lambda v = \vec{0} \Leftrightarrow Av - \lambda I_n v = \vec{0} \Leftrightarrow (A - \lambda I_n)v = \vec{0}.$$

- ▶  $(A - \lambda I_n)v = \vec{0}$  es un sistema de ecuaciones lineal **homogéneo** (términos independientes nulos). Por tanto, siempre es compatible:
  - ▶ Si  $\det(A - \lambda I_n) \neq 0$ , entonces es compatible determinado y su única solución es  $v = \vec{0}$
  - ▶ Si  $\det(A - \lambda I_n) = 0$ , entonces es compatible indeterminado y tiene infinitas soluciones.
- ▶ Queremos encontrar vectores propios  $v \neq \vec{0}$ , luego imponemos  $\det(A - \lambda I_n) = 0$  (**ecuación característica**). Las raíces de esta ecuación con incógnita  $\lambda$  son los valores propios.
- ▶ Para cada valor propio obtenido  $\{\lambda_i\}_{i=1}^k$  se obtiene el máximo número de vectores linealmente independientes como que verifican  $(A - \lambda_i I_n)v = \vec{0}$ ,  $1 \leq i \leq k$ .

## Ejemplo

- ▶ Sea  $A = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix}$ .
- ▶ Ec. caract.:  $\det(A - \lambda I_2) = 0 \rightarrow \det \begin{pmatrix} 7 - \lambda & -10 \\ 5 & -8 - \lambda \end{pmatrix} = 0 \rightarrow \lambda^2 + \lambda - 6 = 0 \rightarrow \lambda_1 = -3, \lambda_2 = 2$ .
- ▶ *Vectores propios:*
  - ▶  $(A - \lambda_1 I_2)v = \vec{0} \rightarrow \begin{pmatrix} 10 & -10 \\ 5 & -5 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} \alpha \\ \alpha \end{pmatrix}, \alpha \in \mathbb{R}.$   
 $\alpha = 1 \rightarrow v_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$
  - ▶  $(A - \lambda_2 I_2)v = \vec{0} \rightarrow \begin{pmatrix} 5 & -10 \\ 5 & -10 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 2\alpha \\ \alpha \end{pmatrix}, \alpha \in \mathbb{R}.$   
 $\alpha = 1 \rightarrow v_2 = \begin{pmatrix} 2 \\ 1 \end{pmatrix}.$

# Otras descomposiciones matriciales

- ▶ No todas las matrices son diagonalizables en  $\mathbb{R}$ .
- ▶ Si  $A$  es cuadrada y no diagonalizable  $\rightarrow$  **Forma canónica de Jordan**.
- ▶ Si  $A$  es rectangular  $\rightarrow$  **Factorización SVD** (*singular value decomposition*)  $\rightarrow$  PCA.
- ▶ Otras factorizaciones útiles:
  - ▶ Factorización  $LU$  (método de eliminación de Gauss).
  - ▶ Factorización de Cholesky (mínimos cuadrados, Montecarlo...).
  - ▶ Factorización  $QR$  (mínimos cuadrados).

## Definición

Una matriz  $A \in \mathbb{R}^{n \times n}$  es simétrica si  $A' = A$

## Teorema

Si  $A \in \mathbb{R}^{n \times n}$  es simétrica, entonces  $A$  es diagonalizable. Además,  $\exists P \in \mathbb{R}^{n \times n}$  ortogonal ( $P' = P^{-1}$ ) tal que  $P'AP = D$ .

## Definición

Una matriz simétrica  $A \in \mathbb{R}^{n \times n}$  es **definida positiva** (respectivamente **semidefinida positiva**) si  $\forall v \in \mathbb{R}^{n \times 1}$ ,  $v \neq \vec{0}$ ,  $v'Av > 0$  (respectivamente  $v'Av \geq 0$ ). Por otra parte,  $A$  es **(semi)definida negativa** si  $-A$  es (semi)definida positiva.

## Ejemplos

1.  $I_n \in \mathbb{R}^{n \times n}$  es definida positiva  $\forall n \in \mathbb{N}$ . En efecto, dado  $v \in \mathbb{R}^{n \times 1}$ ,  $v \neq \vec{0}$ ,  
 $v'I_nv = v'v = \|v\|_2^2 > 0$ .
2.  $0_n \in \mathbb{R}^{n \times n}$  es semidefinida positiva  $\forall n \in \mathbb{N}$ . En efecto, dado  $v \in \mathbb{R}^{n \times 1}$ ,  $v \neq \vec{0}$ ,  
 $v'0_nv = 0$ .
3.  $A = \begin{pmatrix} 7 & -10 \\ 5 & -8 \end{pmatrix} \in \mathbb{R}^{2 \times 2}$  no es (semi)definida positiva, pues, por ejemplo, tomando  $v' = (1, 1)$ , se tiene  $v'Av = -6 < 0$ .

## Definición

Sea  $A \in \mathbb{R}^{n \times n}$  y  $k \in \{1, 2, \dots, n\}$ . El **menor principal dominante** de orden  $k$  asociado a  $A$ , al que denotaremos por  $A_k$ , es  $A_k = \det(A(1:k, 1:k))$ ; es decir, el determinante de la submatriz formada por las primeras  $k$  filas y columnas.

## Teorema

Sea  $A \in \mathbb{R}^{n \times n}$  una matriz simétrica. Los enunciados siguientes son equivalentes:


- ▶  $A$  es definida positiva (respectivamente, semidefinida positiva).
- ▶  $A_k > 0$ ,  $\forall k \in \{1, 2, \dots, n\}$  (respectivamente,  $A_k \geq 0$ ).
- ▶  $\forall \lambda \in \mathbb{R}$  valor propio de  $A$ ,  $\lambda > 0$  (respectivamente,  $\lambda \geq 0$ ).

## Definición

Un **tensor** es un objeto invariante con respecto a un cambio de coordenadas.

## Ejemplos

1. Los **escalares** en  $\mathbb{R}$  son tensores.
2. Los **vectores**  $v$  de un espacio vectorial  $V$  son tensores.
3. Los elementos del conjunto  $V^*$ , formado por las aplicaciones lineales de la forma  $V \rightarrow \mathbb{R}$ , llamados **covectores**, son tensores.
4. Las aplicaciones lineales entre dos espacios vectoriales  $V$  y  $W$ , de la forma  $V \rightarrow W$ , tienen representación como tensor.
5. En consecuencia, las matrices de  $\mathbb{R}^{m \times n}$  tienen representación como tensor.
6. Tensores métricos (ecuaciones de campo de Einstein).



► Vector:  $v = \begin{pmatrix} 5 \\ 4 \end{pmatrix}$


► Base  $\mathcal{B} = \{e_1, e_2\}$ , donde:

$$e_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, e_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

►  $v = 5e_1 + 4e_2$

► Coordenadas de  $v$  en la base  $\mathcal{B}$ :

$$\begin{bmatrix} 5 \\ 4 \end{bmatrix}_{\mathcal{B}}$$



► Vector:  $v = \begin{pmatrix} 5 \\ 4 \end{pmatrix}$

► Base  $\tilde{\mathcal{B}} = \{\tilde{e}_1, \tilde{e}_2\}$ , donde:


$$\tilde{e}_1 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}, \tilde{e}_2 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

►  $v = 2\tilde{e}_1 + 3\tilde{e}_2$

► Coordenadas de  $v$  en la base  $\tilde{\mathcal{B}}$ :

$$\begin{bmatrix} 2 \\ 3 \end{bmatrix}_{\tilde{\mathcal{B}}}$$





► Vector:  $v = \begin{pmatrix} 5 \\ 4 \end{pmatrix}$


► Base  $\tilde{\mathcal{B}} = \{\tilde{e}_1 = 2e_1, \tilde{e}_2 = 2e_2\}$ ,  
donde:

$$\tilde{e}_1 = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \tilde{e}_2 = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$$

►  $v = 2.5\tilde{e}_1 + 2\tilde{e}_2$

► Coordenadas de  $v$  en la base  $\tilde{\mathcal{B}}$ :

$$\begin{bmatrix} 2.5 \\ 2 \end{bmatrix}_{\tilde{\mathcal{B}}} = \frac{1}{2} \begin{bmatrix} 5 \\ 4 \end{bmatrix}_{\mathcal{B}}$$



► Vector:  $v = \begin{pmatrix} 5 \\ 4 \end{pmatrix}$

► Base  $\tilde{\mathcal{B}} = \{\tilde{e}_1 = \frac{1}{2}e_1, \tilde{e}_2 = \frac{1}{2}e_2\}$ ,  
donde:

$$\tilde{e}_1 = \begin{pmatrix} \frac{1}{2} \\ 0 \end{pmatrix}, \tilde{e}_2 = \begin{pmatrix} 0 \\ \frac{1}{2} \end{pmatrix}$$

►  $v = 10\tilde{e}_1 + 8\tilde{e}_2$


► Coordenadas de  $v$  en la base  $\tilde{\mathcal{B}}$ :

$$\begin{bmatrix} 10 \\ 8 \end{bmatrix}_{\tilde{\mathcal{B}}} = 2 \begin{bmatrix} 5 \\ 4 \end{bmatrix}_{\mathcal{B}}$$

- ▶ Diremos que una componente de un tensor es **contravariante** si ésta varía en proporción inversa con respecto a un cambio de coordenadas.
- ▶ **Ejemplo:** coordenadas de un vector con respecto a una base.
- ▶ Diremos que una componente de un tensor es **covariante** si ésta varía en proporción directa con respecto a un cambio de coordenadas.
- ▶ **Ejemplo:** coordenadas de un vector  $v$  formadas a partir de su producto escalar con los elementos de la base  $\mathcal{B} = \{b_i\}_{i=1}^n$ :

$$\begin{bmatrix} v \cdot b_1 \\ \vdots \\ v \cdot b_n \end{bmatrix}$$

- ▶ Los arrays multidimensionales son casos particulares de objetos que tienen representación de tensor.
- ▶ El **rango** de un tensor en forma de array representa las dimensiones espaciales en términos de la disposición de sus entradas.
  - ▶ Un escalar  $x \in \mathbb{R}$  tiene rango 0.
  - ▶ Un vector  $v \in \mathbb{R}^n$  tiene rango 1 (y dimensión  $n$ ).
  - ▶ Una matriz  $A \in \mathbb{R}^{n \times n}$  tiene rango 2 (y dimensión  $n$ ).
  - ▶ Un array del tipo  $A \in \mathbb{R}^{n \times n \times n}$  tiene rango 3 (y dimensión  $n$ ).



- ▶ En general,  $T_{j_1, \dots, j_q}^{i_1, \dots, i_p}$  es un tensor de tipo  $(p, q)$  ( $p$  componentes contravariantes y  $q$  componentes covariantes), con rango  $p + q$ .

## Ejemplos

1. *Audio PCM Mono de 2 segundos, con frecuencia de muestreo de 48 kHz (48000 muestras por segundo).*
  - ▶ *Rango: 1.*
  - ▶ *Dimensión: 96000.*
2. *Audio PCM Stereo de 3 segundos, con frecuencia de muestreo 44.1 kHz (44100 muestras por segundo).*
  - ▶ *Rango: 2.*
  - ▶ *Dimensión:  $2 \times 132300$ .*
3. *Imagen monocroma, con 600 píxeles de anchura y 800 píxeles de altura.*
  - ▶ *Rango: 2.*
  - ▶ *Dimensión:  $600 \times 800$ .*

## Ejemplos

4. *Imagen RGB, con 2000 píxeles de anchura y 1200 píxeles de altura.*
  - ▶ *Rango:* 3.
  - ▶ *Dimensión:*  $3 \times 2000 \times 1200$ .
5. *Vídeo monocromo de 1 minuto, a 30 fps (frames por segundo), con resolución 720p:*
  - ▶ *Rango:* 3.
  - ▶ *Dimensión:*  $1800 \times 1280 \times 720$ .
6. *Vídeo RGB de 40 segundos, a 60 fps (frames por segundo), con resolución 1080p:*
  - ▶ *Rango:* 4.
  - ▶ *Dimensión:*  $2400 \times 3 \times 1920 \times 1080$ .

# ¡Muchas gracias!



**Universidad  
Internacional  
de Valencia**

**Contacto:**

[victormanuel.campello@campusviu.es](mailto:victormanuel.campello@campusviu.es)

